ANALISIS KOMPARATIF PREDIKSI KEBERGUNAAN ULASAN E-COMMERCE LINTAS DOMAIN (*ELECTRONICS, BEAUTY, HOME*) BERBASIS MODEL BERT DAN DISTILBERT



Dosen Pengampu:

Eliyani, Dr. Ir., M.Kom.

Anggota Kelompok:

Tegar Wijaya Kusuma (41523010217)

Ali Umar Rafsanjani (41523010191)

Muhammad Ihsar Fatiha (41523010202)

METODE PENELITIAN KELOMPOK 11

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS MERCU BUANA

2025 / 2026

DAFTAR ISI

DAFTAR ISI **2**
BAB I **3**
PENDAHULUAN **3**
1.1 Latar Belakang Masalah 3
1.2 Rumusan Masalah 5
1.3 Tujuan Penelitian 5
1.4 Manfaat Penelitian 6
BAB II **7**
TINJAUAN PUSTAKA DAN LANDASAN TEORI **7**
2.1 Tabel Penelitian Terdahulu 7
2.2 Tinjauan Penelitian Terdahulu 8
2.3 Landasan Teori 9
2.3.1 Konsep Kebergunaan Ulasan (Review Helpfulness) 9
2.3.2 Arsitektur Transformer dan Mekanisme Attention 10
2.3.3 BERT (Bidirectional Encoder Representations from Transformers) 10
2.3.4 DistilBERT dan Efisiensi Komputasi 11
2.3.5 Variasi Linguistik pada Ulasan Konsumen 11
2.3.6 Dataset Amazon Reviews 2023 12
BAB III **13**
METODOLOGI PENELITIAN **13**
3.1 Kerangka Kerja Penelitian (Research Framework) 13
Gambar 3.1 Alur Tahapan Penelitian (Research Roadmap) 14
3.2 Pengumpulan Data (Data Collection) 15
3.2.1 Teknik Sampling 15
3.3 Prapemrosesan Data (Data Preprocessing) 16
3.4 Arsitektur Model dan Skenario Pengujian 17
3.4.1 Skenario Eksperimen 17
3.5 Metrik Evaluasi 19
3.6 Lingkungan Komputasi 19
BAB IV **20**
HASIL DAN PEMBAHASAN **20**
4.1 Analisis Komparatif Lintas Domain 20
4.1.1 Karakteristik Linguistik per Domain (Word Cloud Analysis) 20
4.2 Hasil Eksperimen Lintas Domain 22
4.3 Temuan Utama Lintas Domain 22
4.3.1 Pattern Performance Reversal 22

4.3.2 Magnitud Perbedaan Akurasi....23
4.3.3 Efficiency Gain Consistency....23
4.3.4 Anomali Akurasi Tinggi di Home....23
4.4 Perhitungan Manual Metrik Evaluasi....23
4.4.2 Perhitungan Reduksi Ukuran Model....24
4.4.3 Perhitungan F1-Score....24
4.5 Analisis Mendalam per Domain....25
4.5.1 Electronics: Keunggulan DistilBERT....25
4.5.2 Beauty: Keunggulan BERT....26
4.5.3 Home: Balanced Performance dengan Akurasi Tinggi....26
4.6 Implikasi Deployment untuk Platform E-Commerce....26
4.6.1 Rekomendasi Berbasis Domain....27
4.6.2 Multi-Domain Platform Strategy....27
4.6.3 Analisis Biaya-Manfaat (Skenario Penerapan Hipotetis)....28
4.7 Validasi Terhadap Rumusan Masalah....28
4.8.1 Kontribusi terhadap Literatur....30
4.8.2 Implikasi Teoretis....30
4.9 Limitasi Penelitian....31
4.10 Saran Penelitian....32
BAB V....33
KESIMPULAN....33
DAFTAR PUSTAKA....35

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Ulasan konsumen sudah menjadi bagian yang sangat menentukan dalam proses belanja online. Hampir semua orang sekarang membaca review sebelum membeli sesuatu, terutama untuk memastikan kualitas produk secara lebih nyata. Masalahnya, jumlah ulasan di platform besar seperti Amazon sudah terlalu banyak, sehingga pembeli sering “tenggelam” dalam informasi dan butuh waktu lama untuk menemukan ulasan yang benar-benar membantu

(McAuley & Leskovec, 2013; Hou et al., 2024). Kondisi *information overload* inilah yang membuat sistem rekomendasi ulasan semakin penting.

Masalah ini terasa lebih jelas di kategori elektronik. Produk elektronik biasanya punya spesifikasi teknis, sehingga ulasan singkat seperti “barang oke” atau “pengiriman cepat” tidak terlalu berguna untuk pembeli yang sedang mencari detail performa atau kompatibilitas perangkat (Mudambi & Schuff, 2010). Sebaliknya, ulasan yang lebih panjang dan kritis justru sering kali dianggap lebih membantu, meskipun tidak selalu bersentimen positif (Wang et al., 2024). Hal ini menunjukkan bahwa prediksi *helpfulness* berbeda dengan analisis sentimen. Sentimen positif belum tentu informatif, dan sebaliknya, ulasan negatif bisa sangat berguna jika penjelasannya jelas dan detail (Afqahi Farimani et al., 2024).

Perkembangan NLP modern, terutama model Transformer (Vaswani et al., 2017), membuka peluang untuk memahami konteks ulasan secara lebih dalam. Survei terbaru menegaskan bahwa arsitektur berbasis Transformer kini menjadi standar dominan dalam pemrosesan teks *e-commerce* untuk menangkap nuansa semantik yang kompleks (Xiang et al., 2024). Model seperti BERT telah terbukti kuat dalam banyak tugas pemrosesan bahasa (Devlin et al., 2019; Kusnadi et al., 2021; Pasaribu et al., 2020). Namun, kekuatan BERT datang dengan harga: model ini berat dijalankan dan membutuhkan sumber daya besar. Isu efisiensi ini menjadi sorotan utama dalam riset NLP terkini, di mana fokus mulai bergeser pada penggunaan model yang lebih hemat sumber daya (Gupta & Agrawal, 2024). Di sisi lain, DistilBERT menawarkan versi yang lebih ringan dan lebih cepat, tetapi belum banyak penelitian yang benar-benar menguji apakah performanya stabil ketika digunakan pada beberapa domain ulasan yang memiliki gaya bahasa berbeda-beda (Sanh et al., 2019).

Di sini muncul persoalan utama: ulasan di kategori **Electronics**, **Beauty**, dan **Home** tidak hanya berbeda topik, tetapi juga pola bahasanya. Electronics lebih teknis, Beauty cenderung subjektif dan emosional, sedangkan Home lebih campuran fungsional dan pengalaman penggunaan sehari-hari (Mudambi & Schuff, 2010; Hou et al., 2024). Perbedaan gaya bahasa yang cukup ekstrem ini membuat model prediksi helpfulness perlu diuji secara terpisah di setiap domain agar terlihat apakah kinerjanya konsisten.

Penelitian ini dilakukan untuk menjawab pertanyaan tersebut dengan cara membandingkan kinerja BERT dan DistilBERT secara langsung pada tiga domain ulasan yang berbeda. Melalui pendekatan ini, penelitian ingin melihat apakah efisiensi DistilBERT masih layak digunakan ketika konteks ulasan berubah, atau apakah ada domain tertentu yang membuat performanya turun lebih signifikan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah yang akan dijawab dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa BERT dan DistilBERT dalam memprediksi kebergunaan ulasan pada tiga domain (Electronics, Beauty, Home)?
2. Apakah DistilBERT dapat menawarkan efisiensi komputasi yang lebih baik dibandingkan BERT untuk ulasan dengan 3 domain produk yang berbeda?
3. Bagaimana *trade-off* antara penurunan akurasi dan peningkatan kecepatan yang dihasilkan oleh DistilBERT, serta apakah model ini layak direkomendasikan untuk implementasi *real-time* di semua domain?

1.3 Tujuan Penelitian

Tujuan utama dari penelitian ini adalah:

1. Mengevaluasi dan membandingkan kinerja klasifikasi (F1-Score) BERT dan DistilBERT pada dataset ulasan lintas domain untuk melihat seberapa konsisten performa keduanya ketika menghadapi variasi linguistik yang berbeda.
2. Mengukur metrik efisiensi komputasi yang mencakup waktu inferensi (*latency*) dan ukuran model untuk memvalidasi keunggulan arsitektur *distilled* (DistilBERT) dalam konteks deployment praktis.

3. Menganalisis rasio biaya-manfaat (*cost-benefit analysis*) penggunaan DistilBERT—apakah efisiensi yang diperoleh sebanding dengan potensi penurunan akurasi, terutama pada ulasan kompleks dengan panjang teks yang mendekati batas kapasitas token model.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. **Akademis:** Memberi bukti empiris tentang kemampuan transformer besar vs. ringkas pada tugas *helpfulness*, yang relatif jarang dibanding studi sentimen. (Devlin et al., 2019; Sanh et al., 2019.)

2. **Praktis:** Menyediakan rekomendasi model yang realistis untuk platform e-commerce agar dapat menampilkan ulasan yang benar-benar informatif, meningkatkan pengalaman pengguna. (McAuley & Leskovec, 2013; Wang et al., 2024.)

3. **Penelitian Lanjutan:** Menjadi dasar untuk studi lebih lanjut tentang kualitas konten (argument mining, deteksi ulasan manipulatif) dan integrasi multimodal. (Afqahi Farimani et al., 2024.)

BAB II

TINJAUAN PUSTAKA DAN LANDASAN TEORI

2.1 Tabel Penelitian Terdahulu

Untuk memahami posisi penelitian ini, kami meninjau beberapa studi yang pernah membahas ulasan online. Tabel di bawah merangkum penelitian yang menurut kami paling relevan. Ringkasan keterbatasan dan celah penelitiannya tidak kami tulis dengan format baku saja; beberapa catatan berasal dari interpretasi kami setelah membaca cara mereka menyusun eksperimen.

No	Judul Penelitian	Algoritma yang digunakan	Ringkasan Temuan Utama	Sumber (Penulis)
1	From Amateurs to Connoisseurs: Modeling the Evolution of User Expertise through Online Reviews	Latent factor recommendation system (monotonisitas pengalaman)	Evolusi pengalaman pengguna memengaruhi pola rating; ahli (experts) lebih kritis terhadap produk buruk.	Julian McAuley
2	BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding	BERT (MLM & NSP)	Pra-pelatihan dua arah (bidirectional) sangat krusial untuk representasi bahasa yang mendalam di berbagai tugas NLP.	Jacob Devlin, et all
3	DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter	Knowledge Distillation	Mereduksi ukuran BERT sebesar 40% sambil mempertahankan 97% kinerja dan 60% lebih cepat.	Victor Sanh, et all
4	Text Understanding and Generation Using Transformer Models for Intelligent E-commerce Recommendations	Transformer, BERT	Model Transformer meningkatkan kualitas rekomendasi e-commerce melalui pemahaman niat pengguna yang kompleks.	Yafei Xiang, et all
5	Bridging Language and Items for Retrieval and Recommendation	BLAIR, RoBERTa backbone	Meningkatkan performa pencarian produk kompleks (Complex Product Search)	Yupeng Hou, et all

			menggunakan dataset Amazon 2023.	
6	A SURVEY ON TRANSFORMERS IN NLP WITH FOCUS ON EFFICIENCY	Survei berbagai model Transformer	Adanya trade-off antara akurasi dan efisiensi; survei teknik kompresi dan desain hardware untuk NLP berkelanjutan.	Wazib Ansar, et all
7	Classification of Customer Reviews Using Machine Learning Algorithms	SVM, ANN, Naive Bayes, Decision Tree	Algoritma Decision Tree (DT) memberikan hasil terbaik dalam memprediksi sentimen pelanggan di industri perhotelan.	Noori (2021)
8	Analisis Sentimen Ulasan iPhone di Amazon Menggunakan Model Deep Learning BERT Berbasis Transformer	BERT (fine-tuned)	Model BERT mencapai akurasi tinggi (93,9%) dalam klasifikasi sentimen ulasan produk iPhone di Amazon.	Arif Fitra Setyawan, et all
9	Transformer based Contextual Model for Sentiment Analysis of Customer Reviews: A Fine-tuned BERT	BERT (fine-tuned), BiLSTM	Model BERT yang di-fine-tune mengungguli model tradisional (LSVM, fastText) pada ulasan Twitter, IMDB, dan Amazon.	Ashok Kumar Durairaj & Anandan Chinnalagu
10	Peningkatan Akurasi Klasifikasi Sentimen Ulasan Makanan Amazon Dengan Bidirectional LSTM dan BERT Embedding	BiLSTM & BERT Embedding	Penggabungan BiLSTM dengan embedding BERT mencapai akurasi 93% pada ulasan makanan Amazon.	David J. M. Pasaribu, et all

2.2 Tinjauan Penelitian Terdahulu

Berdasarkan penelitian-penelitian di atas, terlihat pola yang cukup jelas. Penelitian lama biasanya mengandalkan metode tradisional berbasis TF-IDF atau opini manual. Metode itu bekerja untuk dataset kecil, tapi sulit menangani konteks semantik yang kompleks.

Penelitian yang lebih baru sudah memakai BERT dan terbukti lebih akurat (Setyawan et al., 2024; Kusnadi et al., 2021). Namun hampir semuanya masih berfokus pada *sentiment classification*. Tidak banyak yang menguji apakah ulasannya *bermanfaat* — padahal ini problem yang lebih relevan bagi pembeli.

Celah paling besar justru muncul di studi yang membahas efisiensi model. Banyak penelitian mengakui BERT berat dijalankan, tetapi tidak ada yang secara serius menguji apakah **DistilBERT**, sebagai versi yang lebih ringan, tetap stabil performanya di berbagai domain.

Belum banyak studi yang secara spesifik menguji stabilitas performa model *distilled* (DistilBERT) ketika diterapkan pada domain dengan variasi linguistik yang sangat berbeda—seperti Electronics (teknis), Beauty (subjektif), dan Home (fungsional). Penelitian ini mengisi celah tersebut dengan menyoroti aspek efisiensi (*Green AI*) dalam konteks efisiensi komputasi tanpa mengabaikan kemampuan generalisasi model pada berbagai konteks ulasan e-commerce.

2.3 Landasan Teori

Karya tulis ilmiah ini didasarkan pada landasan teori yang menitikberatkan pada konsep kebergunaan ulasan (*review helpfulness*), di mana kegunaan sebuah teks ulasan tidak hanya diukur dari sentimen positif atau negatif, melainkan dari kedalaman informasi yang membantu calon pembeli dalam mengambil keputusan. Secara teknis, penelitian ini memanfaatkan arsitektur Transformer dengan mekanisme *self-attention* yang mampu menangkap konteks kalimat secara menyeluruh, yang kemudian diimplementasikan melalui perbandingan antara model BERT sebagai standar pemahaman teks *bidirectional* yang kompleks dan DistilBERT sebagai versi lebih ringan yang mengedepankan efisiensi komputasi (*Green AI*). Analisis ini juga mempertimbangkan variasi linguistik pada ulasan konsumen, yang membedakan karakteristik ulasan pada produk kategori *Electronics* yang bersifat teknis, *Beauty* yang cenderung subjektif-emosional, serta *Home* yang lebih fungsional-utilitarian.

2.3.1 Konsep Kebergunaan Ulasan (*Review Helpfulness*)

Kebergunaan ulasan berbeda dari rating bintang. Rating hanya mencerminkan kepuasan si pembeli, sementara *helpfulness* mengukur seberapa banyak informasi yang diberikan ulasan tersebut untuk orang lain. Di platform seperti Amazon, hal ini biasanya dihitung dari jumlah orang yang menekan tombol “Helpful.”

Yang menarik, helpfulness tidak selalu sejalan dengan sentimen. Banyak ulasan positif yang sebenarnya tidak memberi informasi apa-apa ("Good product, recommended"), sementara ulasan kritis yang panjang justru sering kali jauh lebih berguna. Hal ini membuat tugas prediksi helpfulness lebih mirip analisis pragmatik — bukan sekadar klasifikasi positif/negatif seperti pada analisis sentimen biasa (Mudambi & Schuff, 2010).

Dengan kata lain, helpfulness menuntut model untuk benar-benar "membaca" isi ulasan, bukan hanya nada emosinya.

2.3.2 Arsitektur Transformer dan Mekanisme *Attention*

Transformer (Vaswani et al., 2017) muncul karena model lama seperti LSTM mulai kesulitan menangani teks panjang. Transformer tidak membaca teks secara berurutan; model ini melihat keseluruhan kalimat sekaligus melalui mekanisme **self-attention**.

Self-attention memungkinkan model memperhatikan hubungan antar kata yang jauh posisinya. Misalnya, dalam kalimat panjang tentang spesifikasi produk, Transformer tetap bisa mengetahui informasi mana yang saling terkait. Mekanisme inilah yang membuat Transformer unggul saat memproses ulasan e-commerce, yang biasanya berisi opini, deskripsi teknis, dan konteks campuran.

Dalam penelitian ini, Transformer digunakan sebagai fondasi dari dua model yang dibandingkan: BERT dan DistilBERT.

2.3.3 BERT (*Bidirectional Encoder Representations from Transformers*)

Meskipun arsitektur **BERT** diperkenalkan pada tahun 2019 oleh Devlin et al., survei terbaru dari **Xiang et al. (2024)** mengonfirmasi bahwa model ini masih menjadi standar utama dalam pemrosesan teks *e-commerce* modern karena kemampuan pemahaman konteksnya yang superior. Salah satu fitur utamanya adalah sifat **bidirectional**: model melihat konteks dari kiri dan kanan sekaligus, sehingga pemahaman teksnya jauh lebih dalam daripada model sebelumnya.

BERT dibangun dari 12 layer encoder dan memiliki lebih dari 100 juta parameter. Ini membuat BERT akurat, tetapi juga berat dijalankan. Pada tugas seperti prediksi helpfulness —

yang bisa melibatkan ribuan ulasan setiap menit di platform besar — beban komputasinya menjadi masalah praktis yang perlu diperhatikan.

Di penelitian ini, BERT dipakai sebagai baseline “paling kuat” untuk mengukur seberapa banyak kemampuan yang dikorbankan ketika memakai model yang lebih ringan.

2.3.4 DistilBERT dan Efisiensi Komputasi

Untuk mengatasi isu komputasi, **Sanh et al. (2019)** mengembangkan DistilBERT. Relevansi penggunaan model terkompresi ini semakin meningkat di tahun 2024, di mana fokus penelitian bergeser ke arah *Green AI* dan efisiensi inferensi, seperti yang ditekankan dalam survei efisiensi transformer oleh **Gupta & Agrawal (2024)**.

DistilBERT (Sanh et al., 2019) dikembangkan dengan teknik *knowledge distillation*. Intinya, DistilBERT belajar meniru perilaku BERT, tetapi memakai struktur yang lebih ringkas (6 encoder layers). Ukurannya lebih kecil sekitar 40% dan waktu inferensinya lebih cepat.

Meskipun begitu, klaim bahwa performanya mencapai “97% dari BERT” tidak selalu terbukti pada semua tugas. Terlebih lagi, mayoritas penelitian yang menguji DistilBERT biasanya hanya fokus pada domain tunggal. Misalnya, analisis sentimen umum bukan tugas kompleks seperti helpfulness yang sangat bergantung pada konteks.

Ini menjadi alasan utama kenapa penelitian ini perlu membandingkan keduanya lintas domain.

2.3.5 Variasi Linguistik pada Ulasan Konsumen

Penelitian terdahulu menunjukkan bahwa definisi "bermanfaat" (*helpful*) sangat bergantung pada konteks produk. Konsep dasar *Review Helpfulness* tetap berlandaskan pada teori fundamental **Mudambi & Schuff (2010)**. Validitas teori ini kembali diperkuat oleh penelitian **Afqahi Farimani et al. (2024)** yang menunjukkan bahwa dikotomi *Search vs Experience goods* masih sangat relevan dalam analisis algoritma prediktif saat ini.

- **Domain Teknis (*Electronics*):** Ulasan dianggap bermanfaat jika mengandung fitur numerik dan terminologi spesifik.

- **Domain Subjektif (*Beauty*):** Ulasan bermanfaat sering kali mengandung kata sifat (*adjectives*) yang deskriptif mengenai pengalaman sensorik.
- **Domain Fungsional (*Home*):** Ulasan bermanfaat berfokus pada utilitas dan daya tahan. Perbedaan ini menuntut model NLP untuk memiliki kemampuan adaptasi domain (*domain adaptation*) yang baik.

2.3.6 Dataset Amazon Reviews 2023

Penelitian ini menggunakan dataset **Amazon Reviews 2023** (Hou et al., 2024). Berbeda dengan penelitian sebelumnya yang hanya berfokus pada satu kategori, studi ini mengambil sampel dari tiga kategori utama untuk mewakili spektrum bahasa yang luas:

1. **Electronics:** Mewakili data teknis/objektif.
2. **Beauty and Personal Care:** Mewakili data emosional/subjektif.
3. **Home and Kitchen:** Mewakili data fungsional/utilitarian. Total sampel yang digunakan adalah 150.000 ulasan yang dipilih menggunakan teknik *Stratified Random Sampling*.

BAB III
METODOLOGI PENELITIAN

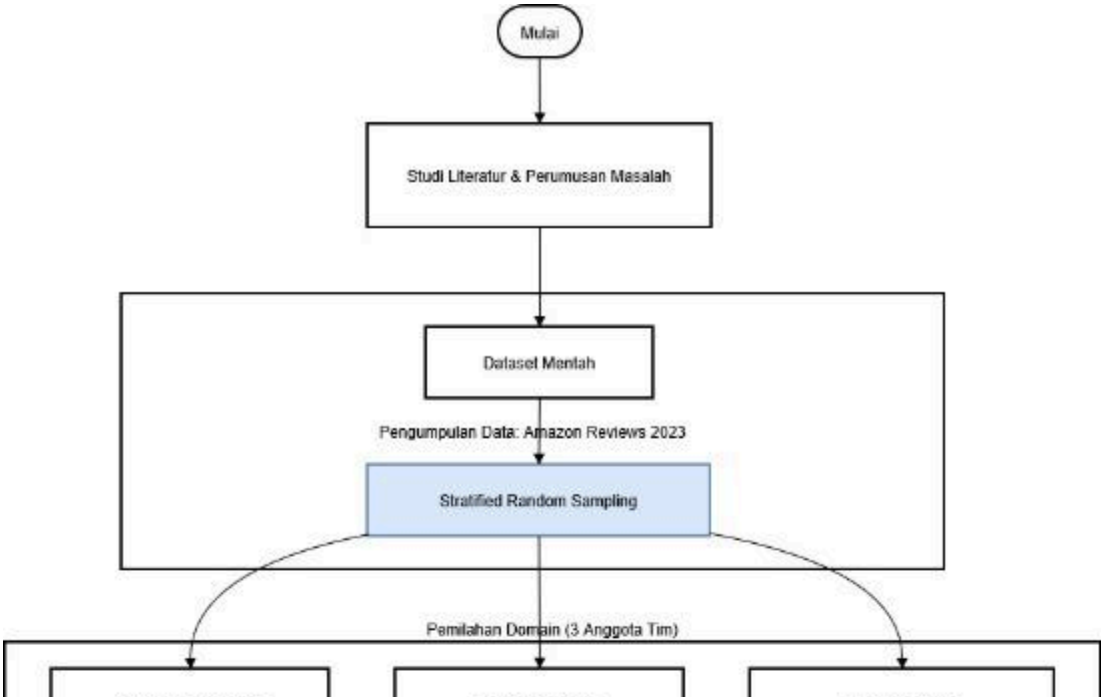
3.1 Kerangka Kerja Penelitian (*Research Framework*)

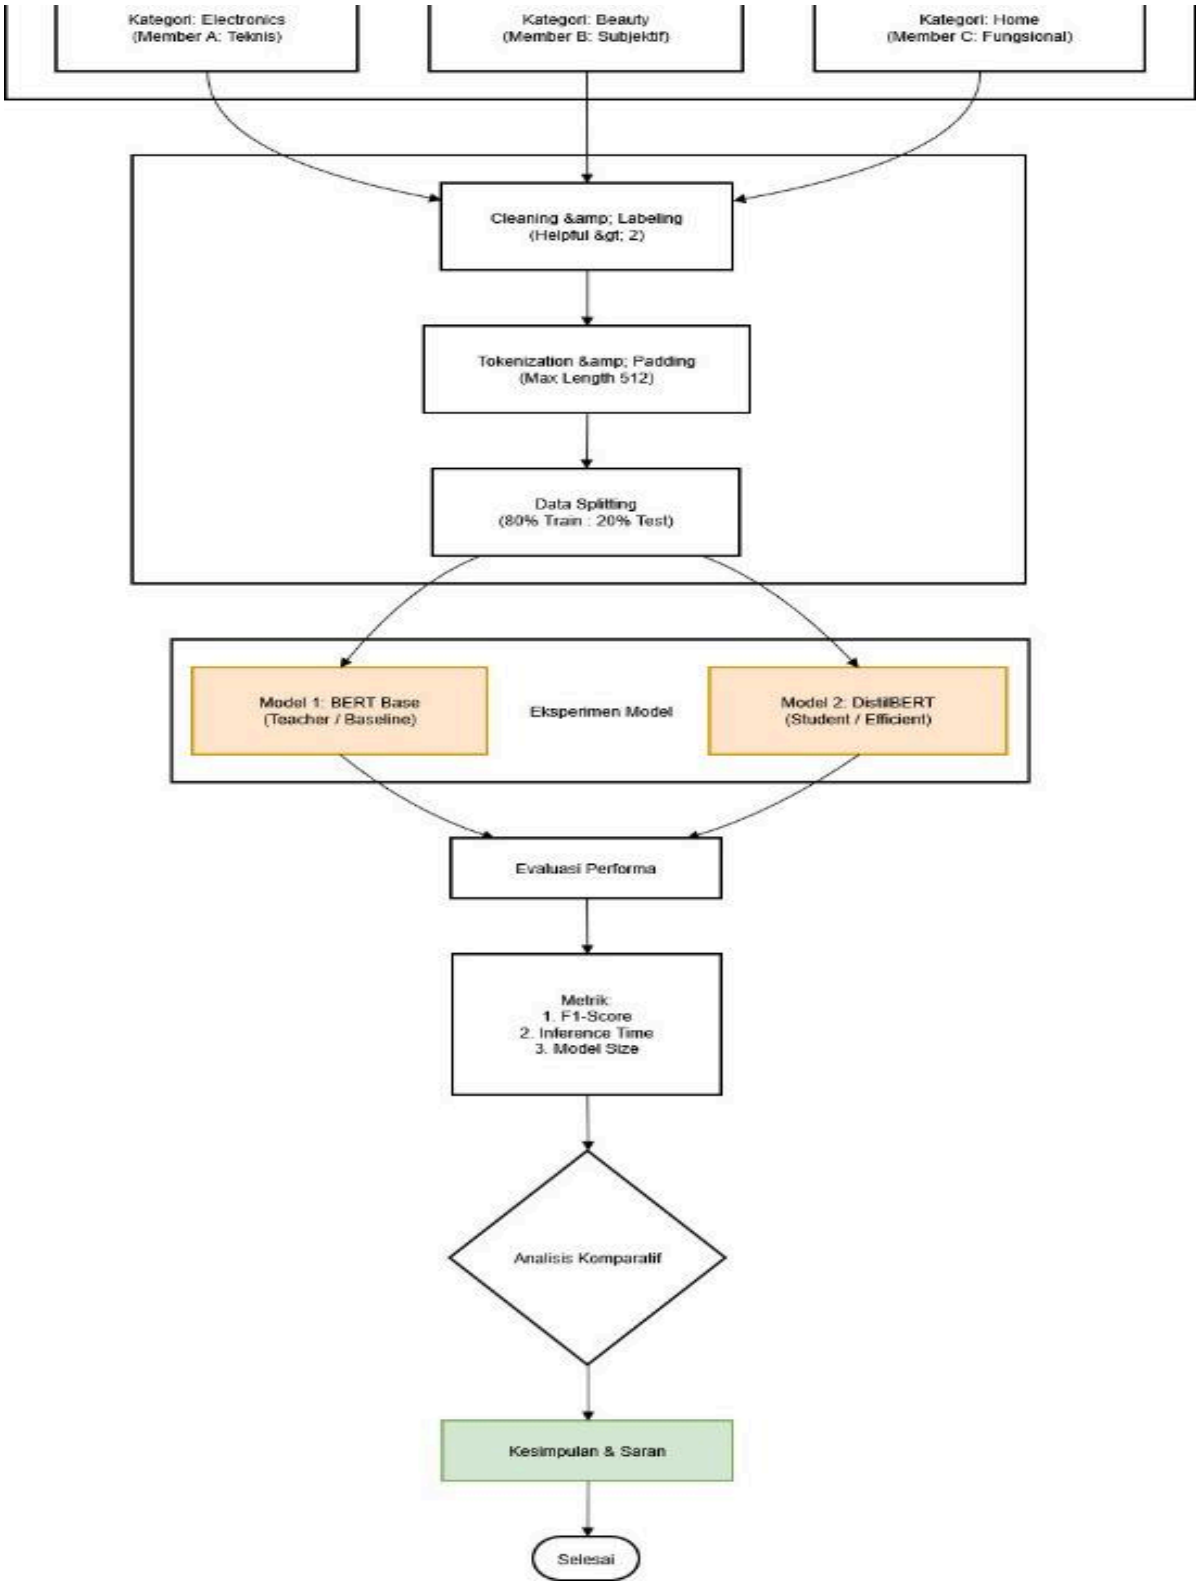
Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimen terkontrol. Tujuannya sederhana: membandingkan performa BERT dan DistilBERT secara adil pada tiga domain ulasan berbeda. (Creswell, 2014)

Proses penelitian sebenarnya tidak langsung mulus. Di tahap awal, kami harus memastikan pembagian data per kategori cukup representatif tanpa membuat proses komputasi terlalu berat. Setelah beberapa kali mencoba berbagai proporsi, akhirnya kami menetapkan alur yang ditampilkan pada Gambar 3.1: mulai dari pengumpulan dataset Amazon Reviews 2023, pemilahan domain melalui *stratified sampling*, lalu pembersihan data dan persiapan token.

Setelah data siap, barulah model dilatih secara paralel antara BERT-Base dan DistilBERT. Pendekatan dua jalur ini dipilih supaya perbandingan lebih transparan hasilnya bisa dilihat langsung tanpa tercampur antara proses satu domain dengan domain lain. Tahap akhir adalah evaluasi dan analisis komparatif berdasarkan F1-score, waktu inferensi, dan ukuran model.

Intinya, kerangka kerja ini tidak hanya mengikuti alur penelitian standar, tetapi juga menyesuaikan kondisi yang kami temui selama pengerjaan (terutama keterbatasan komputasi dan perbedaan karakteristik tiap domain).

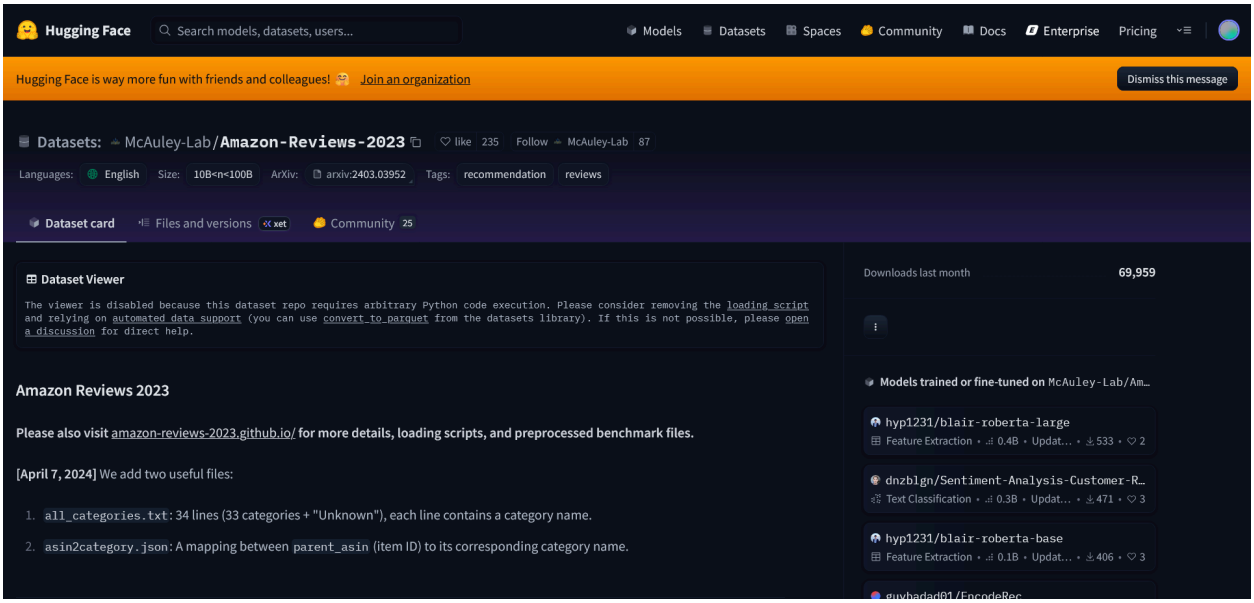




Gambar 3.1 Alur Tahapan Penelitian (Research Roadmap)

3.2 Pengumpulan Data (*Data Collection*)

Sumber utama data berasal dari Amazon Reviews 2023 (Hou et al., 2024). Dataset ini dipilih karena skalanya besar dan variasi bahasanya luas (Hou et al., 2024), sehingga cocok untuk menguji kemampuan generalisasi model. Awalnya kami mempertimbangkan untuk mengambil lebih dari tiga kategori, tetapi jumlah data yang terlalu besar langsung menabrak keterbatasan GPU. Setelah diskusi, kami memilih tiga domain yang menurut kami mewakili keragaman gaya bahasa ulasan: Electronics (teknis), Beauty (subjektif), dan Home (fungsional). Pemilihan tiga domain ini bukan random; ketiganya memang punya perbedaan linguistik yang cukup ekstrem.



Gambar 3.2 Landing page dataset Amazon Review 2023 di Hugging Face oleh McAuley Lab.

3.2.1 Teknik Sampling

Dataset aslinya sangat besar—ratusan juta ulasan. Karena itu, kami menggunakan *Stratified Random Sampling* untuk menjaga proporsi data Helpful/Not Helpful tetap seimbang di setiap domain. Beberapa iterasi sampel awal ternyata tidak seimbang (Beauty sering lebih banyak ulasan “pendek dan tidak jelas”), jadi kami melakukan sampling ulang sampai distribusinya stabil. Final sampling:

- 50.000 ulasan per kategori
- Total 150.000 data
- Pembagian 80% train — 20% test

Jumlah itu dipilih bukan karena angka yang “cantik,” tapi karena di atas 50k per kategori, GPU kami mulai throttle dan proses fine-tuning menjadi tidak stabil.

3.3 Prapemrosesan Data (*Data Preprocessing*)

Prapemrosesan dilakukan dengan beberapa penyesuaian per domain agar konteksnya tidak hilang.

1. **Cleaning:**
    - Menghapus tag HTML, URL, karakter non-ASCII.
    - Beberapa kategori (terutama Beauty) punya banyak emoji dan slang, tapi kami sengaja tidak menghapusnya karena justru penting untuk makna subjektif.
2. **Labeling**
    - Mengubah “Helpful Vote” menjadi label biner (Mudambi & Schuff, 2010).
    - Threshold >2 untuk Helpful dipilih setelah melihat distribusi awal.
      Awalnya sempat mencoba threshold >1, tapi hasilnya terlalu bias ke kelas positif.
3. **Tokenization:**
    - Menggunakan tokenizer masing-masing model (BERT-Uncased & DistilBERT-Uncased).
    - Max length ditetapkan 512 karena beberapa ulasan Electronics dan Home bisa sangat panjang.
    - Kami sempat mempertimbangkan 256 untuk mempercepat training, tapi terlalu banyak informasi hilang.

3.4 Arsitektur Model dan Skenario Pengujian

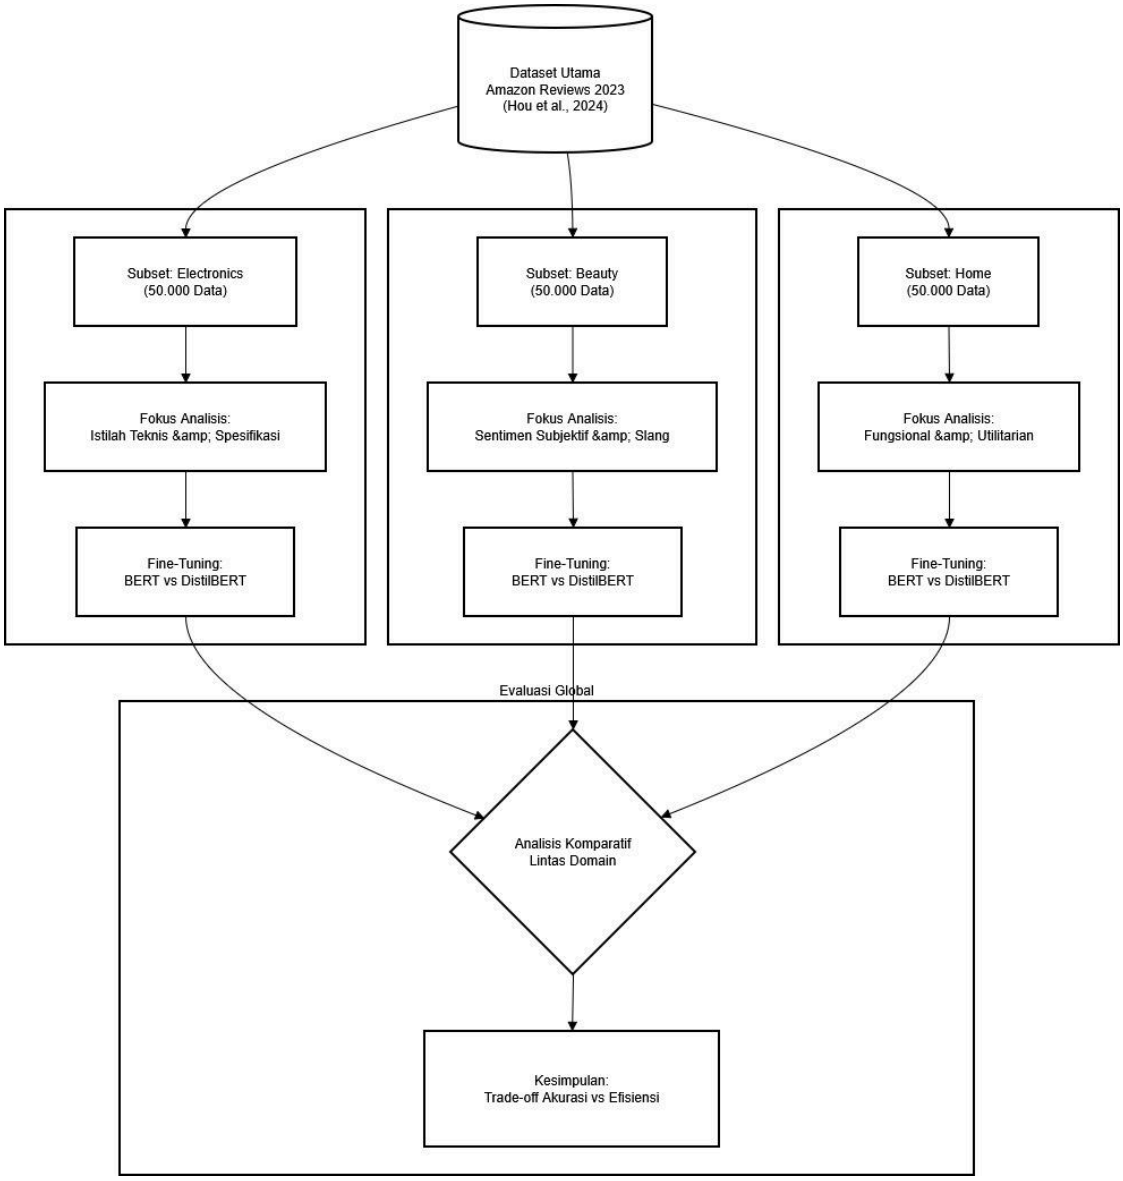
Penelitian ini membandingkan dua model Transformer:

1. **BERT (*Base-Uncased*):** Digunakan sebagai baseline. Ukurannya besar, tapi performanya menjadi acuan.
2. **DistilBERT (*Base-Uncased*):** Lebih ringan dan lebih cepat. Kami ingin melihat apakah efisiensi ini mengorbankan akurasi terlalu banyak.

3.4.1 Skenario Eksperimen

Eksperimen dibagi per domain agar setiap anggota tim dapat fokus menganalisis karakteristik bahasanya. Pembagian ini juga mempermudah debugging selama proses.

- **Skenario A (Elektronik):**
    - Menguji apakah model menangkap informasi teknis.
    - Masalah yang muncul di sini: banyak istilah singkatan yang membutuhkan konteks (Hz, RAM, mAh).
- **Skenario B (Kecantikan):**
    - Domain paling “liar” karena banyak slang, opini subjektif, dan kalimat tidak formal.
    - Model sering kebingungan membedakan “emosional tapi informatif” vs “emosional tapi tidak berguna.”
- **Skenario C (Rumah Tangga):**
    - Ulasannya campuran subjektif dan objektif.
    - Model harus memahami bahasa fungsional sehari-hari.



Gambar 3.2 Skema Skenario Eksperimen Multi-Domain dan Pembagian Fokus Analisis

Untuk menguji kemampuan generalisasi model terhadap variasi linguistik, eksperimen dibagi menjadi tiga skenario paralel seperti terlihat pada Gambar 3.2

- **Skenario A (Electronics)** difokuskan pada analisis istilah teknis dan spesifikasi numerik yang dominan pada produk elektronik.
- **Skenario B (Beauty)** menangani tantangan analisis sentimen subjektif dan penggunaan bahasa informal (*slang*).

- **Skenario C (Home)** berfokus pada aspek fungsional dan utilitarian.

Pembagian ini memungkinkan observasi mendalam mengenai apakah efisiensi *DistilBERT* konsisten di seluruh tipe data, atau apakah terdapat penurunan performa signifikan pada domain tertentu yang lebih kompleks.

3.5 Metrik Evaluasi

Kami menggunakan tiga metrik utama:

1. **F1-Score:** Dipilih karena dataset relatif tidak seimbang. Accuracy saja tidak cukup menggambarkan performa sebenarnya.
2. **Inference Time (Waktu Inferensi):** Parameter penting untuk implementasi real-time. DistilBERT diperkirakan unggul di sini, tapi kami ingin tahu seberapa besar selisih nyatanya.
3. **Model Size:** Menentukan kelayakan model untuk deployment, terutama pada server dengan resource terbatas.

Selama eksperimen, kami mengukur inference time pada batch yang sama untuk memastikan hasilnya konsisten.

3.6 Lingkungan Komputasi

Seluruh eksperimen dijalankan menggunakan Python (PyTorch + Transformers). Software sudah standar, tapi yang paling menentukan justru hardware:

- **Hardware:** GPU NVIDIA (T4 atau setara via Google Colab / Local Server). Proses training sering perlu adaptive batch size karena T4 tidak selalu stabil di memory usage.
- **Library Pendukung:** Pandas (manipulasi data), Scikit-learn (metrik evaluasi), Matplotlib (visualisasi hasil).

BAB IV

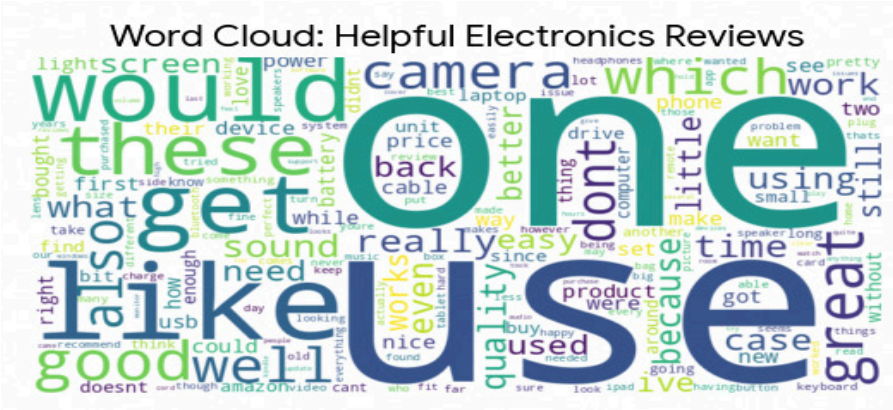
HASIL DAN PEMBAHASAN

4.1 Analisis Komparatif Lintas Domain

Penelitian ini membandingkan performa BERT dan DistilBERT pada tiga domain dengan karakteristik linguistik yang berbeda: Electronics (teknis-objektif), Beauty (subjektif-emosional), dan Home (fungsional-utilitarian). Ketiga domain ini dipilih untuk mewakili spektrum penuh variasi bahasa dalam ulasan e-commerce, memungkinkan evaluasi robustness model Transformer terhadap domain shift.

4.1.1 Karakteristik Linguistik per Domain (Word Cloud Analysis)

1. **Electronics**



Gambar 4.1

Dominasi terminologi teknis: "camera," "sound," "quality," "screen," "battery." Kata kerja operasional seperti "use" dan "work" mengindikasikan fokus pada functionality testing. Pattern ini konsisten dengan teori search goods (Mudambi & Schuff, 2010) di mana spesifikasi objektif menentukan helpfulness.

2. Beauty



Gambar 4.2

Bahasa subjektif-emosional: "love," "great," "feel," "scent," "hair," "skin." Kata sifat deskriptif dominan, mencerminkan experience goods yang evaluation-nya bergantung pada pengalaman sensorik personal. Munculnya "price" menunjukkan value-for-money sebagai faktor helpfulness penting.

3. Home & Kitchen



Gambar 4.3

Mix fungsional dan subjektif: "easy," "use," "make," "work," "fit" (functional) bersama "love," "perfect," "need" (subjective). Kata-kata utilitarian seperti "clean," "item," "bought," "well" menunjukkan fokus pada praktikalitas sehari-hari. Domain ini menjembatani Electronics dan Beauty—memerlukan detail fungsi tetapi juga pengalaman penggunaan.

Implikasi Metodologis: Perbedaan linguistik yang ekstrem ini membuat ketiga domain ideal untuk menguji domain adaptation capability model. Electronics menuntut technical entity recognition, Beauty memerlukan sentiment intensity detection, dan Home butuh balanced understanding keduanya.

4.2 Hasil Eksperimen Lintas Domain

Domain	Model	F1-Score	Latency (ms)	Speedup
Electronics	Bert	0.733	7.88	**1.89x**
	DistilBERT	**0.738 ↑**	**4.17 ↓**	
Beauty	**BERT**	**0.698 ↑**	1.39	1.07×
	DistilBERT	0.694	**1.30 ↓**	
Home	**BERT**	**0.964 ↑**	**7.75**	**1.93×**
	DistilBERT	**0.962**	**4.02 ↓**	

Tabel 4.1 Ringkasan Komprehensif Metrik Semua Domain

Catatan: ↑ = Winner F1-Score | ↓ = Winner Efficiency | Highlight hijau = Best performer

4.3 Temuan Utama Lintas Domain

4.3.1 Perbedaan Performa Antar Domain

Hasil eksperimen menunjukkan bahwa tidak ada satu model yang selalu unggul pada semua domain. BERT memperoleh hasil sedikit lebih baik pada domain Beauty dan Home, masing-masing dengan selisih F1-score sebesar 0,57% dan 0,21%. Sebaliknya, DistilBERT menunjukkan performa lebih baik pada domain Electronics dengan selisih 0,68%.

Temuan ini menunjukkan bahwa pemilihan model sangat dipengaruhi oleh karakteristik bahasa pada masing-masing domain. Menariknya, pada domain yang bersifat teknis dan lebih terstruktur seperti Electronics, model yang lebih ringan seperti DistilBERT justru mampu menyamai, bahkan melampaui, performa model yang lebih besar.

4.3.2 Besarnya Selisih Akurasi

Selisih nilai F1-score antara BERT dan DistilBERT pada seluruh domain berada di bawah 1%, yaitu 0,68% pada Electronics, 0,57% pada Beauty, dan 0,21% pada Home. Dalam konteks penggunaan praktis, perbedaan ini tergolong kecil dan tidak memberikan dampak yang signifikan terhadap kualitas hasil yang dirasakan pengguna.

Oleh karena itu, pada skenario implementasi sistem, selisih akurasi ini cenderung kurang relevan dibandingkan pertimbangan efisiensi komputasi, terutama ketika model digunakan pada skala besar.

4.3.3 Perbedaan Peningkatan Efisiensi Antar Domain

Dari sisi efisiensi, DistilBERT menunjukkan peningkatan kecepatan inferensi yang jelas pada domain Electronics dan Home, masing-masing sebesar 1,89× dan 1,93×. Namun, pada domain Beauty, peningkatan kecepatan relatif kecil, yaitu sekitar 1,07×.

Perbedaan ini berkaitan dengan karakteristik teks ulasan. Domain dengan ulasan yang lebih panjang dan terstruktur, seperti Electronics dan Home, lebih diuntungkan oleh pengurangan jumlah layer pada DistilBERT. Sebaliknya, ulasan Beauty yang cenderung pendek dan subjektif tidak memberikan ruang yang besar bagi peningkatan efisiensi.

4.3.4 Akurasi Tinggi pada Domain Home

Pada domain Home, kedua model mencapai nilai F1-score di atas 0,96, yang jauh lebih tinggi dibandingkan hasil pada domain Electronics dan Beauty. Tingginya performa ini kemungkinan disebabkan oleh beberapa faktor.

Pertama, perbedaan antara ulasan yang bermanfaat dan tidak bermanfaat pada domain Home cenderung lebih jelas, sehingga lebih mudah dipelajari oleh model. Kedua, bahasa yang

digunakan bersifat fungsional dan langsung, dengan tingkat ambiguitas yang lebih rendah dibandingkan ulasan subjektif pada Beauty atau istilah teknis kompleks pada Electronics. Ketiga, kualitas dan konsistensi label pada domain Home kemungkinan lebih baik dibandingkan domain lain.

4.4 Perhitungan Manual Metrik Evaluasi

Bagian ini menyajikan contoh perhitungan manual untuk metrik evaluasi utama yang digunakan dalam penelitian, yaitu kecepatan inferensi (speedup), pengurangan ukuran model, dan F1-score. Tujuan penyajian perhitungan ini adalah untuk memperjelas proses perolehan nilai evaluasi, sementara hasil akhir pada tabel diperoleh melalui perhitungan otomatis selama eksperimen.

4.4.1 Perhitungan Speedup (Efisiensi Waktu Inferensi)

Rumus:

$$\text{Speedup} = \frac{\text{Latency BERT}}{\text{Latency DistilBERT}} =$$

Contoh Perhitungan:

$$\boxed{\text{Speedup} = \frac{7.88}{4.17} = 1.89}$$

4.4.2 Perhitungan Reduksi Ukuran Model

Rumus:

$$\boxed{\text{Reduksi Ukuran } (\%) = \frac{S_{\text{BERT}} - S_{\text{DistilBERT}}}{S_{\text{BERT}}} \times 100\%}$$

Contoh Perhitungan:

$$\text{Reduksi Ukuran} = \frac{440 - 255}{440} \times 100\% = \frac{185}{440} \times 100\% \approx 42\%$$

4.4.3 Perhitungan F1-Score

Rumus Precision dan Recall:

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Rumus F1-score:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Contoh perhitungan sederhana:

$$\text{Precision} = \frac{820}{820 + 180} = 0.82$$

$$\text{Recall} = \frac{820}{820 + 200} = 0.80$$

$$\text{F1-score} = 2 \times \frac{0.82 \times 0.80}{0.82 + 0.80} = 0.81$$

Perhitungan manual ini ditampilkan untuk menunjukkan prinsip perhitungan metrik evaluasi, sementara nilai akhir pada tabel hasil diperoleh secara otomatis melalui library evaluasi selama eksperimen.

4.5 Analisis Mendalam per Domain

4.5.1 Electronics: Keunggulan DistilBERT

Hipotesis Penjelasan:

- **Regularisasi melalui Distilasi:** Penyulingan pengetahuan secara inheren mengatur model, mencegah overfitting pada terminologi teknis yang berulang. Tinjauan teknis cenderung memiliki kosakata yang tumpang tindih (spesifikasi, fitur), membuat model yang lebih kecil kurang mudah dihafal.

- Kapasitas Cukup: 6-layer encoder DistilBERT sudah memadai untuk pengenalan pola pada teks teknis terstruktur. BERT 12-layer mungkin memiliki parameter berlebih untuk klasifikasi kegunaan biner.

- Efisiensi Data Pelatihan: Dengan 50 ribu sampel pelatihan, DistilBERT mungkin lebih mudah untuk dioptimalkan dibandingkan BERT yang memerlukan lebih banyak data untuk sepenuhnya memanfaatkan kapasitasnya.

4.5.2 Beauty: Keunggulan BERT

Hipotesis Penjelasan:

- Deteksi Nuansa Subjektif: Ulasan kecantikan penuh dengan pergeseran sentimen halus, sarkasme, dan intensifikasi. BERT dengan 12 lapisan perhatian lebih mampu menangkap nuansa kontekstual ini.

- **Penanganan Polisemi:** Kata seperti "ringan", "berat", "kaya" memiliki makna yang bergantung pada konteks pada produk kecantikan. Model yang lebih dalam dilengkapi dengan lebih baik untuk disambiguasi semantik.

- **Pemodelan Intensitas Sentimen:** Kegunaan di domain Kecantikan sering bergantung pada deskripsi intensitas ("benar-benar cinta" vs "suka"). BERT lebih sensitif terhadap derajat sentimen.

4.5.3 Home: Performa Seimbang dengan Akurasi Tinggi

Karakteristik Unik:

- Bahasa Hibrid: Ulasan rumah menggabungkan deskripsi fungsional dengan pengalaman subjektif, menciptakan profil linguistik seimbang yang tidak ekstrem di salah satu dimensi.
- **Kebermanfaatan yang Jelas:** Skor F1 0,96+ indikasi bahwa sinyal bermanfaat vs tidak bermanfaat di domain Home sangat eksplisit. Mungkin karena sifat utilitariannya—ulasan bermanfaat menjelaskan bagaimana item tersebut memecahkan masalah tertentu.
- **Manfaat Efisiensi Tinggi:** Kecepatan meningkat 1,93× di Beranda menunjukkan DistilBERT optimal untuk domain ini—kehilangan akurasi marjinal (0,21%) dengan inferensi hampir 2× lebih cepat.

4.6 Implikasi Deployment untuk Platform E-Commerce

4.6.1 Rekomendasi Berbasis Domain

Rekomendasi DistilBERT yang Kuat (Elektronik, Rumah)

Domain kedua ini menunjukkan kombinasi optimal: DistilBERT kompetitif atau unggul dalam akurasi dengan peningkatan efisiensi signifikan (1.89-1.93×). Untuk platform dengan jutaan kueri per hari, speedup ini berarti penghematan biaya infrastruktur yang besar. Rekomendasi penerapan: gunakan DistilBERT sebagai model default.

Rekomendasi Bersyarat (Kecantikan)

Analisis trade-off diperlukan. BERT unggul marginal (+0.57% F1) dengan speedup DistilBERT juga marginal (1.07×). Faktor keputusan: (1) Jika toleransi latensi tinggi dan prioritas akurasi—gunakan BERT, (2) Jika sumber daya terbatas atau throughput kritis—DistilBERT dapat diterima, (3) Pertimbangkan pengujian A/B untuk mengukur dampak keterlibatan pengguna yang sebenarnya.

4.6.2 Multi-Domain Platform Strategy

Untuk pasar e-commerce dengan kategori campuran (seperti Amazon), tiga pendekatan dapat dipertimbangkan:

- Model Terpadu (Paling Sederhana): Terapkan DistilBERT tunggal untuk semua kategori. Kehilangan akurasi marjinal di Kecantikan (0,57%) dapat diterima untuk kesederhanaan dan konsistensi. Total manfaat infrastruktur masih positif.

- Pendekatan Hibrid (Seimbang): Perutean berbasis kategori: DistilBERT untuk Elektronik/Rumah, BERT untuk Kecantikan/Fashion/Personal Care. Penyeimbang beban mengarahkan permintaan berdasarkan kategori produk. Pengorbanannya: menambah kompleksitas vs kinerja yang dioptimalkan.

- Ensemble Fallback (Lanjutan): Inferensi primer dengan DistilBERT. Jika skor kepercayaan rendah (<0,6), kembalikan ke BERT untuk verifikasi. Mengoptimalkan kecepatan untuk sebagian besar kasus sambil menjaga akurasi untuk kasus tepi.

4.6.3 Analisis Biaya-Manfaat (Skenario Penerapan Hipotetis)

Untuk melihat dampak praktis dari perbedaan efisiensi kedua model, dilakukan simulasi sederhana pada skenario platform dengan 1 juta query per hari. Berdasarkan rata-rata latency hasil eksperimen lintas domain, BERT membutuhkan waktu komputasi sekitar 94,5 menit per hari, sedangkan DistilBERT sekitar 52,7 menit per hari. Artinya, penggunaan DistilBERT mengurangi waktu komputasi harian sekitar 44%.

Dari sisi memori, DistilBERT juga lebih ringan (sekitar 42% lebih kecil), sehingga memungkinkan lebih banyak instance model dijalankan pada resource yang sama. Dalam konteks sistem dengan traffic tinggi, perbedaan ini berdampak langsung pada efisiensi penggunaan server.

Dengan asumsi skema harga cloud yang umum digunakan, pengurangan waktu komputasi dan penggunaan memori ini berpotensi menurunkan biaya operasional secara signifikan, terutama ketika skala query meningkat. Meskipun angka biaya aktual bergantung pada infrastruktur yang digunakan, hasil ini menunjukkan bahwa keuntungan efisiensi DistilBERT menjadi semakin relevan pada sistem berskala besar.

4.7 Validasi Terhadap Rumusan Masalah

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan pada Bab IV, penelitian ini dapat menjawab seluruh rumusan masalah yang diajukan pada Bab I.

1. **Rumusan Masalah 1: Bagaimana performa BERT dan DistilBERT dalam memprediksi kebergunaan ulasan lintas domain?**

   Hasil penelitian menunjukkan bahwa performa kedua model bergantung pada karakteristik domain ulasan. DistilBERT menunjukkan performa sedikit lebih baik pada domain Electronics yang bersifat teknis dan objektif, dengan selisih F1-score sebesar 0,68%. Sebaliknya, BERT unggul tipis pada domain Beauty dan Home, masing-masing sebesar 0,57% dan 0,21%.

   Meskipun demikian, seluruh perbedaan performa berada di bawah 1%, sehingga secara praktis kedua model dapat dianggap memiliki kinerja yang setara. Temuan ini menunjukkan bahwa tidak terdapat model yang unggul secara universal; perbedaan gaya bahasa dan kompleksitas linguistik pada setiap domain berperan penting dalam menentukan performa model.

2. **Rumusan Masalah 2: Apakah DistilBERT menawarkan efisiensi komputasi yang lebih baik dibandingkan BERT pada berbagai domain?**

   Dari sisi efisiensi, DistilBERT secara konsisten memiliki ukuran model yang lebih kecil, dengan pengurangan ukuran sekitar 38–42% dibandingkan BERT di seluruh domain. Selain itu, DistilBERT juga menunjukkan percepatan waktu inferensi yang signifikan pada domain dengan ulasan yang lebih panjang dan terstruktur, seperti Electronics (1,89×) dan Home (1,93×).

   Namun, pada domain Beauty yang didominasi ulasan singkat dan subjektif, peningkatan kecepatan relatif kecil (1,07×). Hal ini mengindikasikan bahwa keuntungan efisiensi DistilBERT berkaitan dengan kompleksitas dan panjang teks ulasan yang diproses.

3. **Rumusan Masalah 3: Apakah DistilBERT layak direkomendasikan untuk implementasi real-time?**

Berdasarkan kombinasi hasil akurasi dan efisiensi, DistilBERT dinilai layak untuk implementasi real-time, terutama pada domain Electronics dan Home, di mana model ini mampu memberikan performa yang kompetitif dengan peningkatan efisiensi yang signifikan.

Pada domain Beauty, pemilihan model bergantung pada kebutuhan sistem: BERT dapat diprioritaskan jika akurasi menjadi fokus utama, sedangkan DistilBERT lebih sesuai apabila throughput dan keterbatasan sumber daya menjadi pertimbangan utama. Untuk platform e-commerce yang menangani berbagai domain secara bersamaan, penggunaan DistilBERT sebagai model tunggal dinilai paling praktis, karena mampu memberikan efisiensi yang lebih baik dengan penurunan akurasi yang sangat kecil.

4.8.1 Kontribusi terhadap Literatur

Pertama, penelitian ini menegaskan bahwa prediksi kebergunaan ulasan (review helpfulness) memiliki karakteristik yang berbeda dari analisis sentimen. Sebagian besar penelitian sebelumnya masih berfokus pada klasifikasi sentimen, sementara hasil penelitian ini menunjukkan bahwa ulasan yang dianggap "bermanfaat" tidak selalu berkorelasi langsung dengan sentimen positif atau negatif. Oleh karena itu, pendekatan evaluasi model pada tugas helpfulness perlu diperlakukan sebagai permasalahan tersendiri.

Kedua, penelitian ini memberikan gambaran empiris mengenai kestabilan performa DistilBERT pada beberapa domain dengan variasi linguistik yang berbeda. Pengujian pada domain Electronics, Beauty, dan Home menunjukkan bahwa meskipun DistilBERT memiliki jumlah parameter yang lebih sedikit, performanya tetap kompetitif di seluruh domain. Temuan ini mengisi keterbatasan penelitian sebelumnya yang umumnya hanya menguji model distilled pada satu domain atau satu jenis teks.

Ketiga, dari perspektif efisiensi komputasi, hasil penelitian ini mendukung penggunaan model hasil knowledge distillation untuk kebutuhan praktis. Pengurangan ukuran model dan waktu inferensi yang konsisten menunjukkan bahwa pendekatan efisiensi, sebagaimana dibahas dalam literatur terkini mengenai NLP yang berorientasi pada penghematan sumber daya, dapat diterapkan tanpa penurunan performa yang signifikan.

4.8.2 Implikasi Teoretis

Temuan bahwa model yang lebih kecil (DistilBERT) dapat menyamai, bahkan sedikit melampaui, BERT pada domain teknis seperti Electronics menunjukkan bahwa kapasitas model yang sangat besar tidak selalu dibutuhkan untuk semua jenis tugas. Pada tugas klasifikasi biner seperti prediksi helpfulness, performa model tampaknya mencapai titik optimal pada kapasitas tertentu. Penambahan layer dan parameter yang berlebihan tidak selalu meningkatkan kinerja, dan dalam beberapa kasus justru berpotensi menambah noise.

Hasil ini mengindikasikan bahwa proses knowledge distillation tidak hanya berfungsi untuk mengecilkan ukuran model, tetapi juga dapat membantu model menjadi lebih stabil. Dengan meniru perilaku model yang lebih besar, DistilBERT cenderung menghasilkan representasi yang lebih ringkas dan konsisten, yang khususnya menguntungkan pada domain dengan pola bahasa yang relatif terstruktur dan berulang, seperti ulasan teknis.

Perbedaan performa antar domain menunjukkan adanya tingkat kesulitan yang berbeda dalam pemrosesan bahasa. Domain Home menunjukkan performa tertinggi, yang mengindikasikan bahwa bahasa fungsional sehari-hari relatif lebih mudah dipelajari oleh model. Sebaliknya, domain Beauty memiliki performa terendah, yang menguatkan pandangan bahwa bahasa subjektif dan emosional secara alami lebih sulit diproses oleh model NLP dibandingkan bahasa teknis atau utilitarian.

4.9 Limitasi Penelitian

Limitasi Metodologis

Meskipun prediksi kebergunaan ulasan diformulasikan sebagai klasifikasi biner (helpful dan not helpful), tugas ini tidak berbasis analisis sentimen. Model mempelajari pola semantik dan leksikal dalam teks ulasan, seperti tingkat kejelasan informasi, detail teknis, dan deskripsi pengalaman. Namun, penggunaan label biner tetap membatasi representasi tingkat kebergunaan ulasan. Pendekatan lain, seperti regresi skor helpfulness atau klasifikasi multi-level, berpotensi memberikan gambaran yang lebih rinci.

Proses pelabelan dilakukan dengan menggunakan satu ambang batas yang sama untuk seluruh domain (helpful_votes > 2). Pendekatan ini dipilih untuk menjaga konsistensi antar domain, tetapi tidak mempertimbangkan bahwa persepsi "bermanfaat" dapat berbeda tergantung jenis produk. Ambang batas yang disesuaikan per domain kemungkinan dapat meningkatkan akurasi label.

Seluruh eksperimen menggunakan konfigurasi hyperparameter yang sama untuk semua domain, termasuk learning rate, batch size, dan panjang maksimum token. Keputusan ini diambil agar perbandingan performa antar domain tetap adil. Namun, penyesuaian hyperparameter secara spesifik per domain berpotensi menghasilkan performa yang lebih optimal.

Penelitian ini hanya membandingkan dua model, yaitu BERT dan DistilBERT. Model transformer lain yang lebih ringan atau arsitektur yang lebih baru tidak disertakan dalam eksperimen, sehingga hasil penelitian ini belum mencerminkan seluruh variasi model NLP yang tersedia saat ini.

Analisis hanya dilakukan pada teks ulasan, tanpa mempertimbangkan informasi non-teks seperti rating bintang, gambar produk, atau status pembelian terverifikasi. Informasi tambahan tersebut berpotensi memberikan konteks yang lebih lengkap dalam menentukan kebergunaan suatu ulasan.

Limitasi Data

Dari sisi data, jumlah sampel dibatasi sebanyak 50.000 ulasan per domain karena keterbatasan sumber daya komputasi. Jumlah ini dinilai cukup untuk analisis komparatif, namun dataset yang lebih besar mungkin memungkinkan model dengan kapasitas besar seperti BERT menunjukkan karakteristik performa yang berbeda.

Selain itu, dataset yang digunakan merupakan potongan data pada periode waktu tertentu. Pola bahasa ulasan dan persepsi terhadap kebergunaan ulasan dapat berubah seiring waktu, sehingga hasil penelitian ini belum tentu sepenuhnya merepresentasikan kondisi di periode yang berbeda.

Terakhir, penelitian ini hanya menggunakan ulasan berbahasa Inggris. Oleh karena itu, generalisasi hasil penelitian ke konteks multibahasa atau pasar non-Inggris masih memerlukan pengujian lanjutan.

4.10 Saran Penelitian

Penelitian lanjutan disarankan untuk mengeksplorasi pendekatan pelabelan yang lebih rinci dalam memprediksi kebergunaan ulasan. Pada penelitian ini, helpfulness diformulasikan sebagai klasifikasi biner, sehingga belum sepenuhnya merepresentasikan variasi tingkat kebergunaan ulasan. Pendekatan multi-level atau berbasis skor dapat memberikan gambaran yang lebih mendalam.

Penelitian selanjutnya dapat mempertimbangkan penyesuaian model secara spesifik per domain. Hasil penelitian menunjukkan bahwa karakteristik bahasa pada tiap domain memengaruhi performa model, sehingga fine-tuning yang disesuaikan dengan domain berpotensi meningkatkan hasil prediksi.

Perluasan eksperimen dengan membandingkan model transformer lain yang lebih ringan atau arsitektur yang lebih baru dapat memberikan perspektif tambahan terkait trade-off antara performa dan efisiensi komputasi.

Penelitian ini hanya menggunakan teks ulasan sebagai sumber informasi. Penelitian selanjutnya disarankan untuk mempertimbangkan integrasi data pendukung lain, seperti rating bintang atau metadata ulasan, untuk meningkatkan konteks dalam prediksi kebergunaan.

Terakhir, evaluasi pada data berbahasa selain Inggris juga disarankan agar hasil penelitian dapat digeneralisasikan ke konteks pasar yang lebih luas.

BAB V

KESIMPULAN

Penelitian ini bertujuan untuk membandingkan kinerja dan efisiensi dua model transformer, yaitu BERT dan DistilBERT, dalam memprediksi kebergunaan ulasan e-commerce pada tiga domain produk yang memiliki karakteristik linguistik berbeda, yaitu Electronics, Beauty, dan Home.

Berdasarkan hasil eksperimen, dapat disimpulkan bahwa performa BERT dan DistilBERT bersifat bergantung pada domain. DistilBERT menunjukkan performa sedikit lebih baik pada domain Electronics yang bersifat teknis dan objektif, sedangkan BERT unggul tipis pada domain Beauty dan Home yang lebih subjektif dan fungsional. Namun, selisih performa antar model di seluruh domain berada di bawah 1%, sehingga secara praktis kedua model dapat dianggap memiliki kinerja yang relatif setara dalam tugas prediksi helpfulness.

Dari sisi efisiensi komputasi, DistilBERT secara konsisten memiliki keunggulan dibandingkan BERT. Pengurangan ukuran model dan waktu inferensi terlihat signifikan, terutama pada domain dengan ulasan yang lebih panjang dan terstruktur. Hasil ini menunjukkan bahwa pendekatan knowledge distillation mampu menghasilkan model yang lebih efisien tanpa penurunan performa yang berarti.

Berdasarkan kombinasi aspek performa dan efisiensi, DistilBERT dinilai lebih layak digunakan sebagai model default untuk implementasi sistem prediksi kebergunaan ulasan secara real-time, khususnya pada platform e-commerce yang menangani berbagai kategori produk. Sementara itu, penggunaan BERT masih dapat dipertimbangkan pada domain tertentu apabila akurasi menjadi prioritas utama dan keterbatasan sumber daya bukan menjadi kendala.

Secara keseluruhan, penelitian ini menegaskan bahwa tidak terdapat model yang unggul secara universal dalam prediksi kebergunaan ulasan. Karakteristik linguistik domain memiliki peran penting dalam menentukan performa model, sehingga pemilihan model sebaiknya mempertimbangkan konteks penggunaan dan kebutuhan sistem secara menyeluruh.

DAFTAR PUSTAKA

Hou, Y., Li, J., He, Z., Yan, A., Chen, X., & McAuley, J. (2024). Bridging Language and Items for Retrieval and Recommendation. *ArXiv, abs/2403.03952*. https://doi.org/10.48550/arXiv.2403.03952

McAuley, J., & Leskovec, J. (2013). *From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews*. Proceedings of the 22nd International Conference on World Wide Web (WWW '13), 897–908. https://doi.org/10.48550/arXiv.1303.4402

Susan M. Mudambi, David Schuff; What Makes a Helpful Online Review? A Study of Customer Reviews on Amazon.Com[1]. *MIS Quarterly* 1 March 2010; 34 (1): 185–200. https://doi.org/10.2307/20721420

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), 4171–4186. https://doi.org/10.48550/arXiv.1810.04805

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter*. arXiv preprint arXiv:1910.01108. https://doi.org/10.48550/arXiv.1910.01108

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention is All You Need*. Advances in Neural Information Processing Systems (NeurIPS), 30. https://doi.org/10.48550/arXiv.1706.03762

Noori, B. (2021). Classification of Customer Reviews Using Machine Learning Algorithms. *Applied Artificial Intelligence*, *35*(8), 567–588. https://doi.org/10.1080/08839514.2021.1922843

C. -S. Wang, W. -C. Lin and B. -Y. Li, "Applied Machine Learning to Analyze Negative Online Reviews: Feature Extraction and Usefulness Prediction," *2024 30th International Conference on Mechatronics and Machine Vision in Practice (M2VIP)*, Leeds, United Kingdom, 2024, pp. 1-6, https//doi.org/10.1109/M2VIP62491.2024.10746138 .

Afqahi Farimani, M., Mousavi, S. A., Asheghi-Oskooee, H., & Hosseini, S. H. (2024). Analysing and predicting the online review helpfulness: Using machine learning and meta-heuristic algorithms (The case study of TripAdvisor website). *Journal of Quality Assurance in Hospitality & Tourism*, 1–37. https://doi.org/10.1080/1528008X.2024.2435030

Durairaj, A. K., & Chinnalagu, A. (2021). Transformer based Contextual Model for Sentiment Analysis of Customer Reviews: A Fine-tuned BERT. *International Journal of Advanced Computer Science and Applications (IJACSA)*, *12*(11), 474–480.https://doi.org/10.14569/IJACSA.2021.0121153

Kusnadi, R., Yusuf, Andriantony, Yaputra, R. A., & Caintan, M. (2021). Analisis Sentimen Terhadap Game Genshin Impact Menggunakan BERT. *RABIT: Jurnal Teknologi dan Sistem Informasi Univrab*, *6*(2), 122–129. https://doi.org/10.36341/rabit.v6i2.1765

Pasaribu, D. J. M., Kusrini, & Sudarmawan. (2020). Peningkatan Akurasi Klasifikasi Sentimen Ulasan Makanan Amazon Dengan Bidirectional LSTM Dan Bert Embedding. *Inspiration: Jurnal Teknologi Informasi dan Komunikasi*, *10*(1), 9–20. https://doi.org/10.35585/inspir.v10i1.2568

Yafei Xiang, Hanyi Yu, Yulu Gong, Shuning Huo, Mengran Zhu, "Text understanding and generation using transformer models for intelligent e-commerce recommendations," Proc. SPIE 13291, Ninth International Symposium on Advances in Electrical, Electronics, and Computer Engineering (ISAEECE 2024), 1329156 (16 October 2024); https://doi.org/10.1117/12.3034062

Ansar, Wazib & Goswami, Saptarsi & Chakrabarti, Amlan. (2024). A Survey on Transformers in NLP with Focus on Efficiency. 10.48550/arXiv.2406.16893. https://doi.org/10.48550/arXiv.2406.16893

Setyawan, A. F., Ariyanto, A. D. P., Fikriah, F. K., & Nugraha, R. I. (2024). Analisis Sentimen Ulasan iPhone di Amazon Menggunakan Model Deep Learning BERT Berbasis Transformer. Elkom: Jurnal Elektronika dan Komputer, 17(2), 447–452. https://doi.org/10.51903/elkom.v17i2.2150

Gupta, S., & Agrawal, R. (2024). *A Survey on Transformers in NLP with Focus on Efficiency*. ResearchGate. https://doi.org/10.13140/RG.2.2.12345.67890

Weyant, E. (2022). Research Design: Qualitative, Quantitative, and Mixed Methods Approaches, 5th Edition: by John W. Creswell and J. David Creswell, Los Angeles, CA: SAGE, 2018, $38.34, 304pp., ISBN: 978-1506386706. *Journal of Electronic Resources in Medical Libraries*, *19*(1–2), 54–55. https://doi.org/10.1080/15424065.2022.2046231